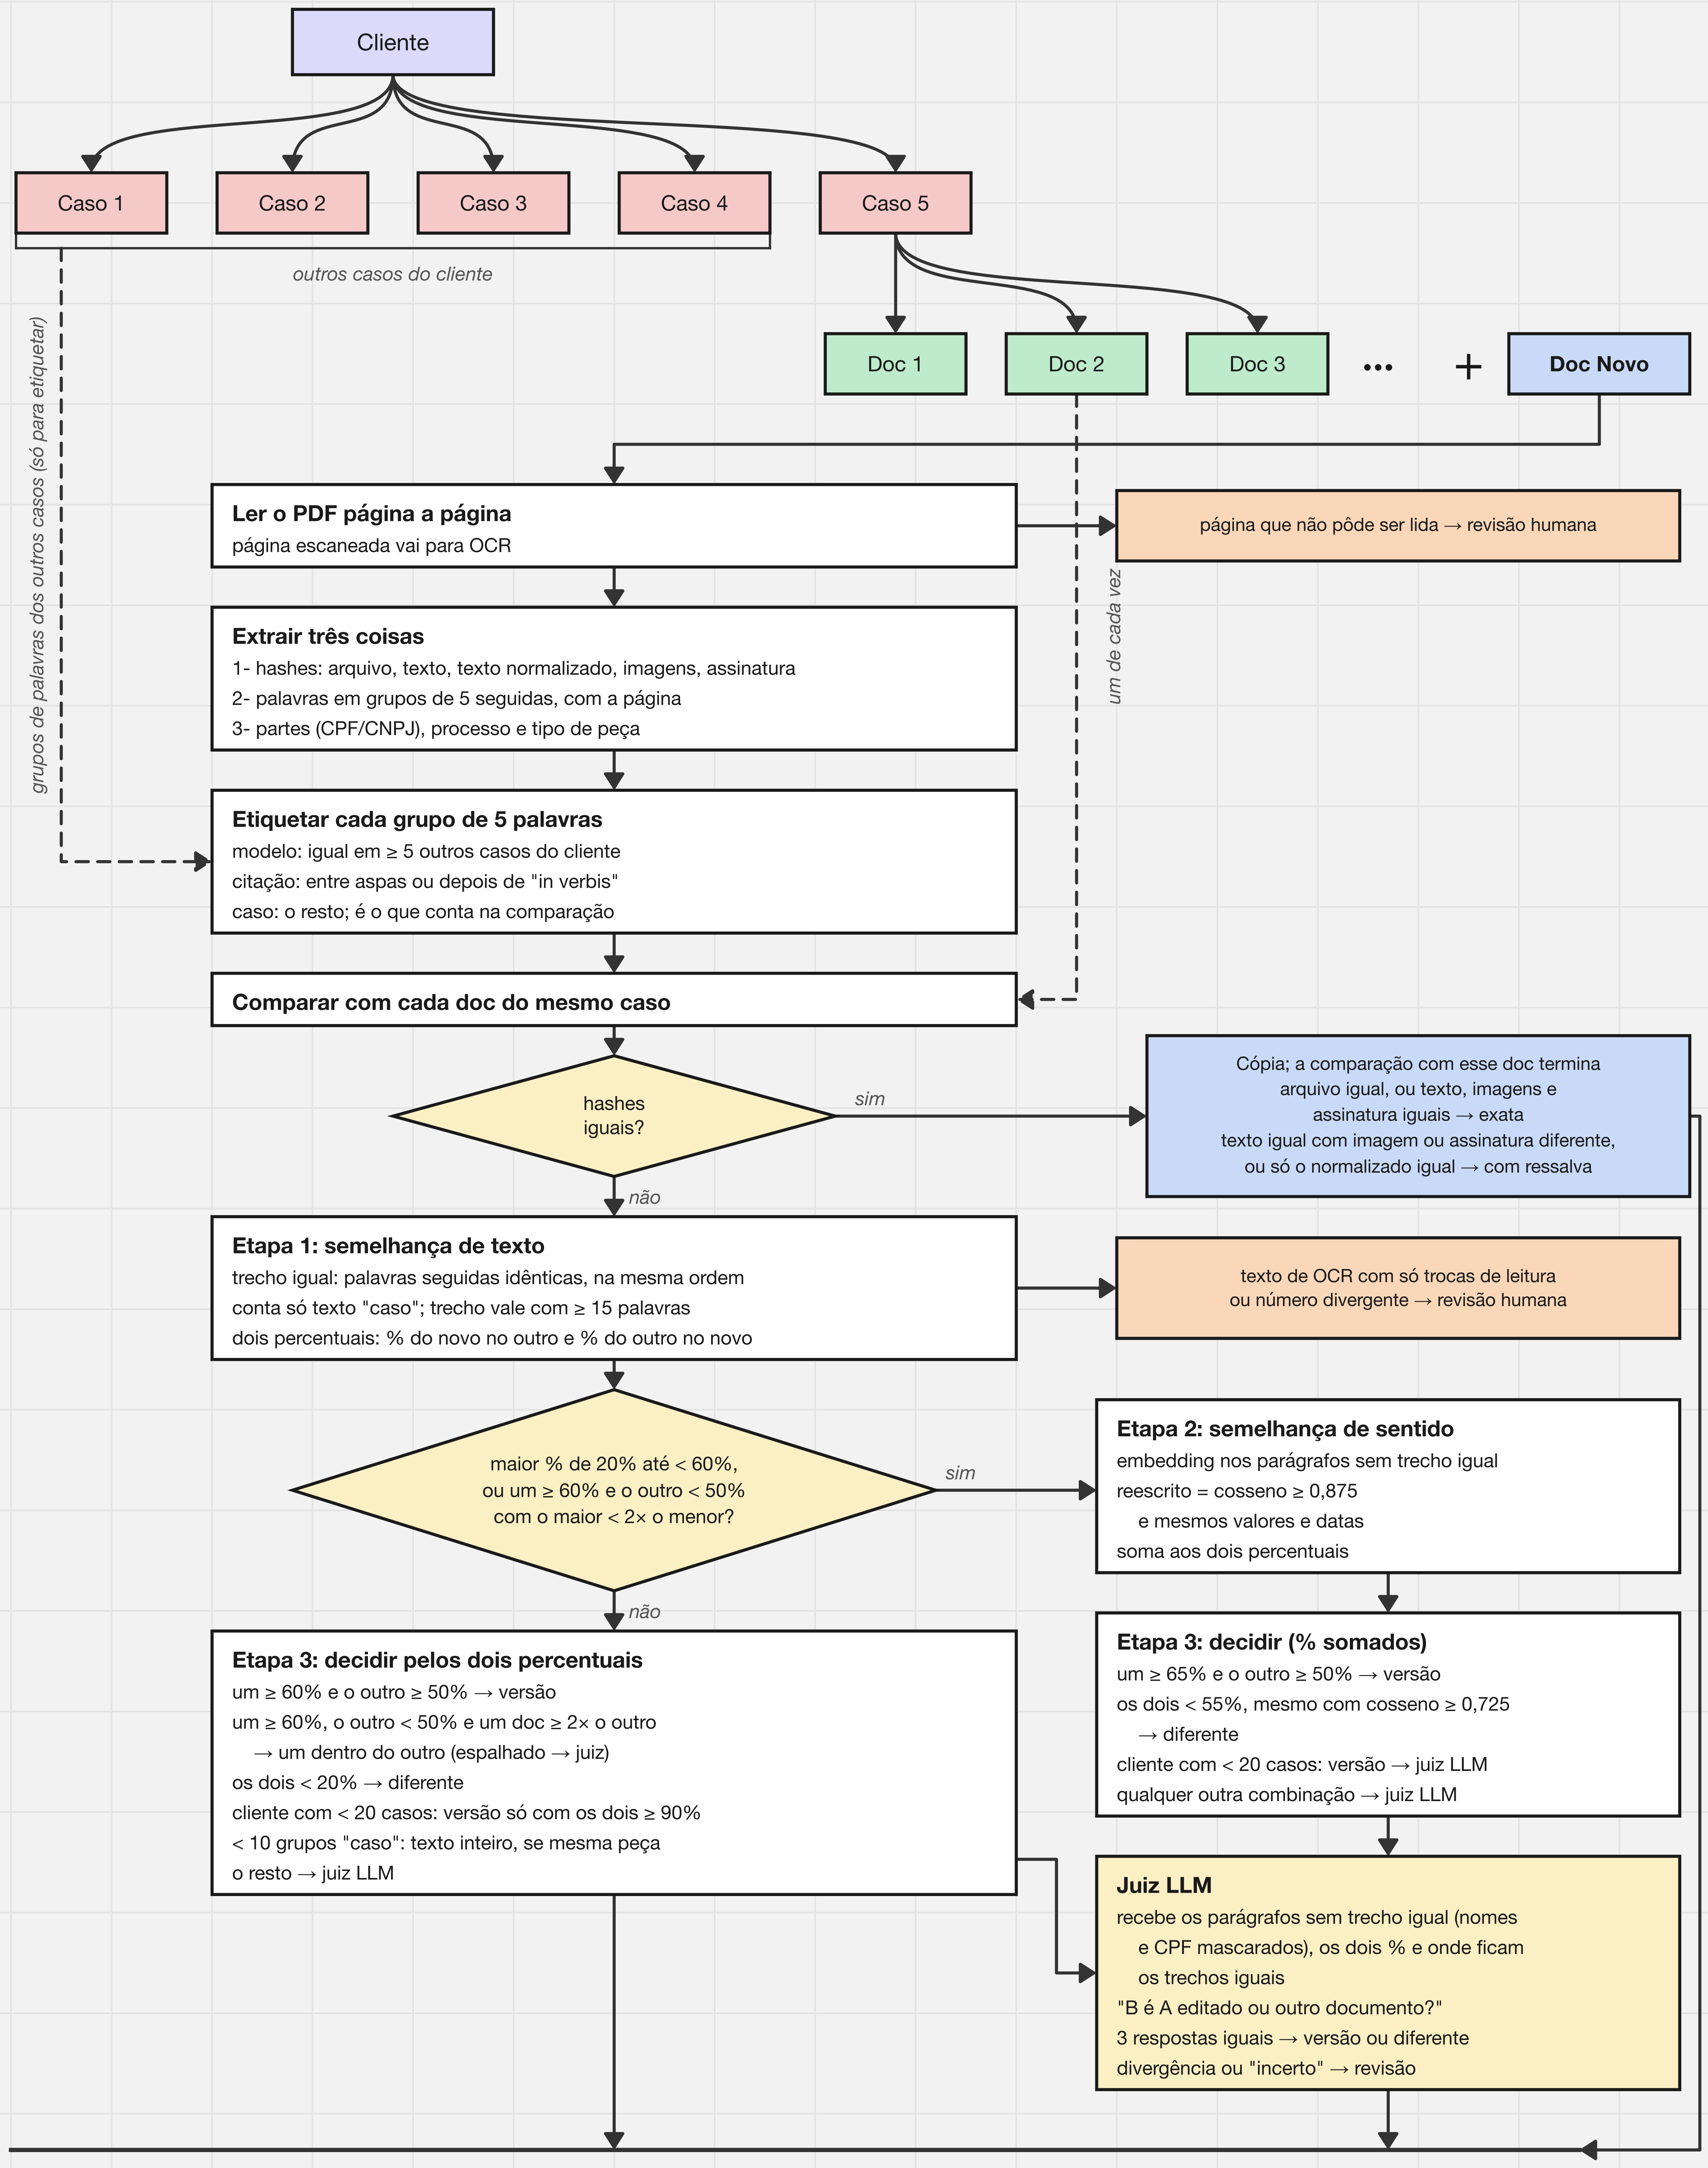

Ler o PDF página a página
página escaneada vai para OCR

página que não pôde ser lida → revisão humana

Extrair três coisas
1- hashes: arquivo, texto, texto normalizado, imagens, assinatura
2- palavras em grupos de 5 seguidas, com a página
3- partes (CPF/CNPJ), processo e tipo de peça

Etiquetar cada grupo de 5 palavras
modelo: igual em ≥ 5 outros casos do cliente
citação: entre aspas ou depois de "in verbis"
caso: o resto; é o que conta na comparação

Comparar com cada doc do mesmo caso

hashes iguais?

Cópia; a comparação com esse doc termina
arquivo igual, ou texto, imagens e assinatura iguais → exata
texto igual com imagem ou assinatura diferente, ou só o normalizado igual → com ressalva

Etapa 1: semelhança de texto
trecho igual: palavras seguidas idênticas, na mesma ordem
conta só texto "caso"; trecho vale com ≥ 15 palavras
dois percentuais: % do novo no outro e % do outro no novo

texto de OCR com só trocas de leitura ou número divergente → revisão humana

maior % de 20% até < 60%, ou um ≥ 60% e o outro < 50% com o maior < 2× o menor?

Etapa 2: semelhança de sentido
embedding nos parágrafos sem trecho igual
reescrito = cosseno ≥ 0,875
e mesmos valores e datas
soma aos dois percentuais

Etapa 3: decidir (% somados)
um ≥ 65% e o outro ≥ 50% → versão
os dois < 55%, mesmo com cosseno ≥ 0,725
→ diferente
cliente com < 20 casos: versão → juiz LLM
qualquer outra combinação → juiz LLM

Etapa 3: decidir pelos dois percentuais
um ≥ 60% e o outro ≥ 50% → versão
um ≥ 60%, o outro < 50% e um doc ≥ 2× o outro
→ um dentro do outro (espalhado → juiz)
os dois < 20% → diferente
cliente com < 20 casos: versão só com os dois ≥ 90%
< 10 grupos "caso": texto inteiro, se mesma peça
o resto → juiz LLM

Juiz LLM
recebe os parágrafos sem trecho igual (nomes e CPF mascarados), os dois % e onde ficam os trechos iguais
"B é A editado ou outro documento?"
3 respostas iguais → versão ou diferente
divergência ou "incerto" → revisão

Registro no caso (nada é apagado)

Cópia	exata ou com ressalva; marcada como cópia e ligada à original
Versão	tipo de peça, partes e processo iguais → mesma peça: as duas no mesmo grupo de versões tipo de peça diferente → versão de outra peça do caso: as duas só ficam ligadas partes ou processo diferentes → mesmo modelo em outro processo: só ligadas, com aviso tipo de peça não lido → ligada como versão, sem afirmar que substitui versão de mais de um doc → ligada a todos; atual = a mais recente pela data de protocolo (sem data, não se afirma) registra onde estão as diferenças: parágrafos novos, removidos e palavras trocadas, com a página
Um dentro do outro	cópia, se o menor estiver inteiro, palavra por palavra (todo o texto), no maior; senão, versão ligado ao outro, com as páginas onde está
Diferente	sem ligação
Revisão	juiz LLM sem 3 respostas iguais ou "incerto"; OCR com só trocas de leitura (provável cópia) ou com número diferente; página que não pôde ser lida → fila de um revisor, que escolhe uma das três classes

Onde cada par cai pelos dois percentuais (a cópia sai antes, pelo hash)

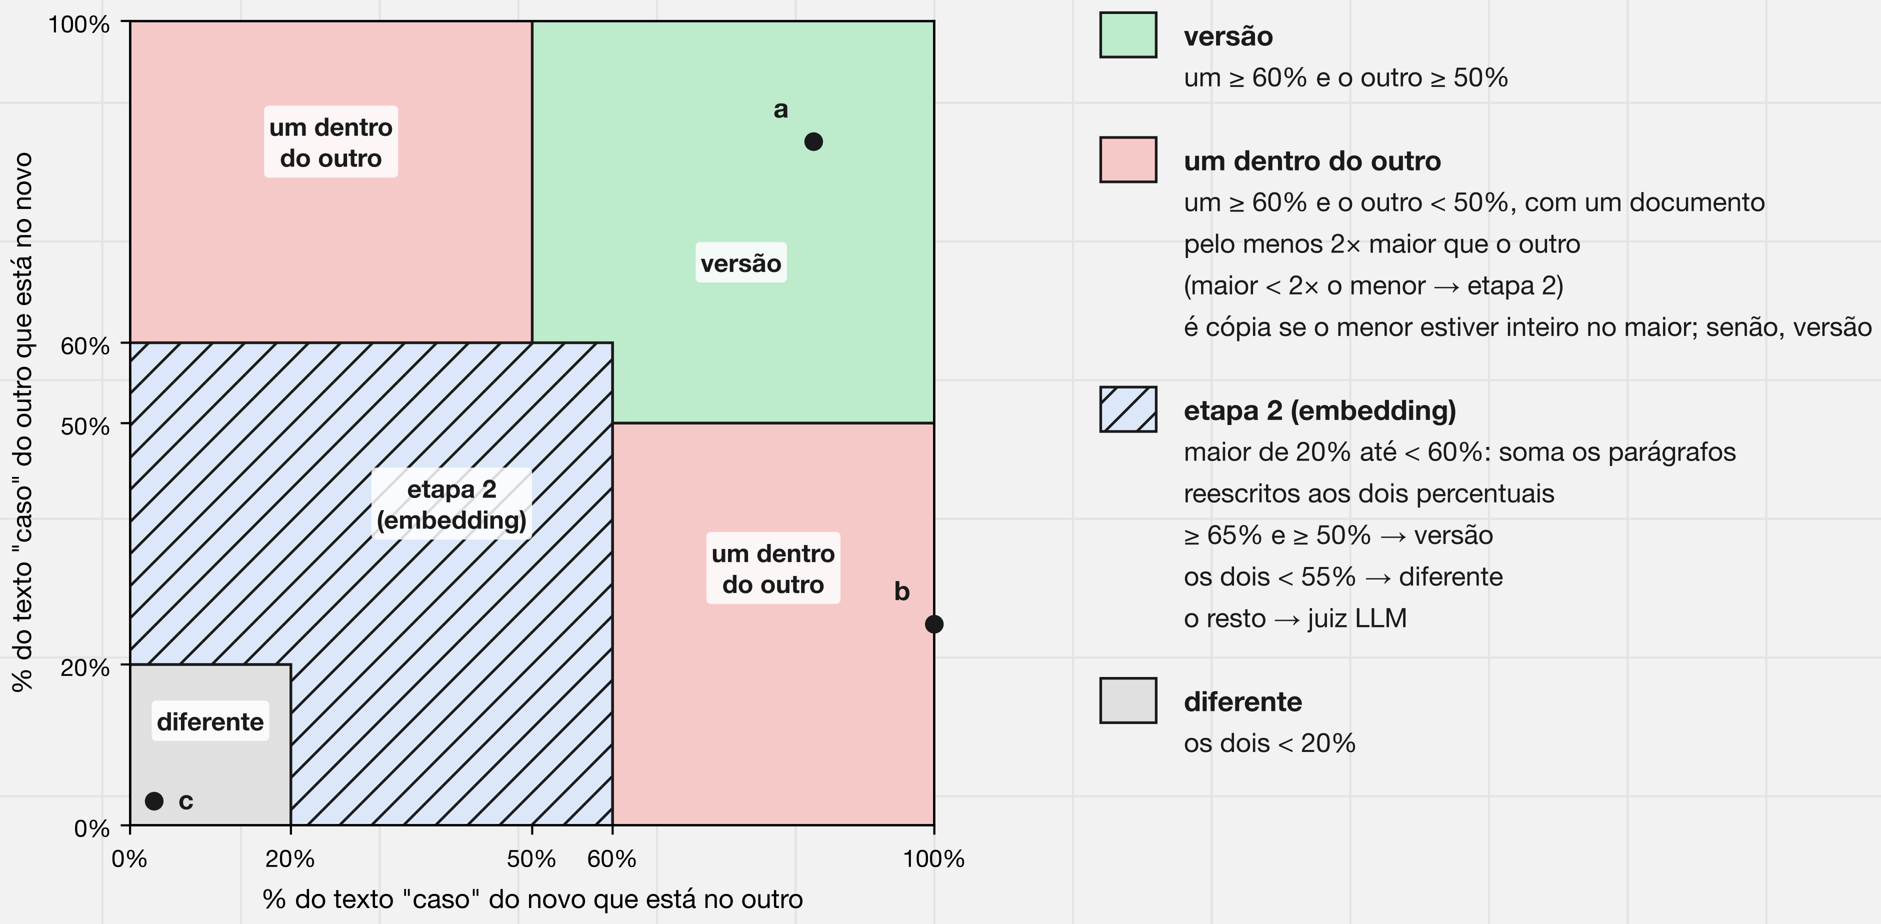

🟩 **versão**
um ≥ 60% e o outro ≥ 50%

🟥 **um dentro do outro**
um ≥ 60% e o outro < 50%, com um documento pelo menos 2× maior que o outro
(maior < 2× o menor → etapa 2)
é cópia se o menor estiver inteiro no maior; senão, versão

▨ **etapa 2 (embedding)**
maior de 20% até < 60%: soma os parágrafos reescritos aos dois percentuais
≥ 65% e ≥ 50% → versão
os dois < 55% → diferente
o resto → juiz LLM

⬜ **diferente**
os dois < 20%

a: petição com 3 de 20 parágrafos trocados e o valor alterado (≈ 85% × 85%)
b: petição juntada dentro de autos 4× maiores (100% × 25%)
c: contestação × inicial do mesmo caso (perto de 0% × 0%)