Questão 1 — Comparação de documentos parecidos

Cada documento novo é comparado com os do mesmo caso: quanto do texto próprio de cada um está escrito igual no outro, nos dois sentidos.
Vocabulário jurídico, texto de modelo do escritório e citações não contam.

A. Fluxo por documento

1. Extrair e normalizar
texto por página; cabeçalho, imagens e assinatura à parte; worker isolado

página sem texto → OCR

2. Indexar
hashes (bytes, texto, normalizado); palavras com página; sequências de 5 palavras; citações; partes e tipo

3. Candidatos no caso
hashes para cópia; todos os docs até ~2 mi de palavras no caso; acima, índice de âncoras

4. Comparar
alinhamento por sementes → dois percentuais + diff + identidade

5. Decidir
portão de igualdade e mapa (B)

Histórico do cliente
≥3 outros casos = texto de modelo (não conta)

Documentos do caso
a comparação nunca sai do caso

usados nas etapas 2–4

assíncrono · idempotente (upload_id) · em série por caso · decisão grava as versões

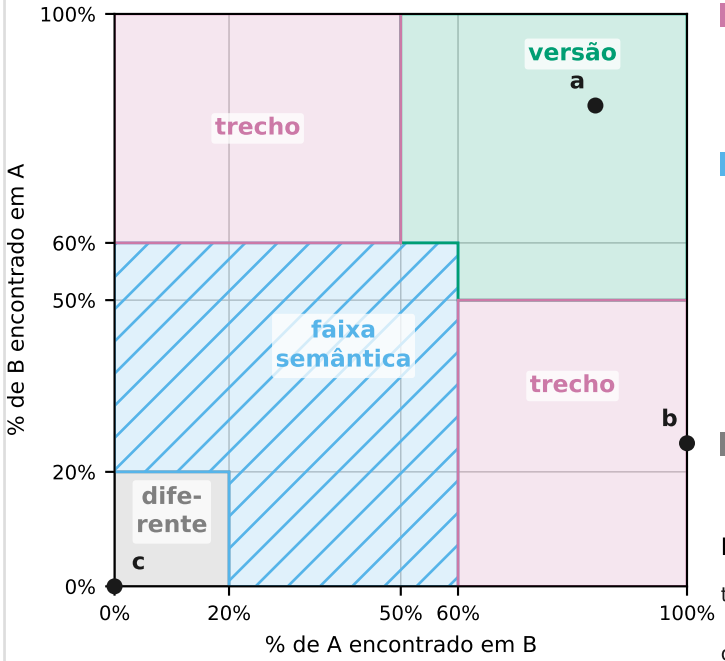
B. Decisão

B1. Portão de igualdade (antes dos percentuais; vale a primeira)

1. bytes iguais	**cópia · exata**
2. extração incompleta ou não confiável; página renderizada diferente	**em revisão**
3. texto, cabeçalho, imagens e assinatura iguais	**cópia · exata**
4. igual após normalização, ou imagem/assinatura diferente	**cópia · com ressalva**
5. texto de OCR e só confusões de letras (número divergente: item a item)	**em revisão**
6. texto próprio < 10 sequências (mesma peça e partes: decide pelo texto inteiro)	**em revisão**

Cópia só sai por igualdade. Nenhum limiar produz cópia.

B2. Os dois percentuais (texto próprio = sem modelo e sem citações)



- maior ≥ 60% e menor ≥ 50%: um documento saiu do outro
- maior ≥ 60%, menor < 50%, um documento ≥ 2× o outro: trecho, se contíguo (senão, revisão)
- maior entre 20% e 60%: decide a cobertura total = literal + parágrafos reescritos (embedding, cosseno ≥ 0,875, valor comum)
  ≥ 65% e ≥ 50% → versão
  < 55% mesmo com 0,725 → diferente
  55%–65% → em revisão
- os dois < 20%: só vocabulário ou modelo em comum (citação explícita vira o vínculo "cita")

a: exemplo do enunciado (84% × 84%)
b: petição dentro de autos 4× maiores (100% × 25%)
c: petições independentes do mesmo modelo (0% × 0%)

B3. Versão de quê?

tipo de peça diferente
→ outra peça do caso
outras partes (CPF) ou processo
→ outra instância do modelo
mesmo tipo, partes e processo
→ mesma peça (substitui)

C. Ação por resultado

Cópia
agrupa · avisa "já existe" · reaproveita as análises · não apaga nada

Versão · mesma peça
liga à anterior · diff com página · alerta de valor, data, CPF, negação

Versão · outra peça ou instância
vínculo · não substitui

Trecho
"contém, págs. x–y"

Diferente
vínculo "cita" ou "reaproveita trechos"

Em revisão
1 item de fila por documento, com os motivos · o revisor escolhe a classe

Calibração
decisões do revisor + auditoria aleatória de 1% das automáticas → rótulos → cortes

LLM (opcional)
resume os trechos alterados · pseudo-nimizado · nunca decide a classe

Cache
por parágrafo: uma nova versão paga só o que mudou